

Uniwersytet Warszawski  
Wydział Nauk Ekonomicznych

Mikołaj Rymajdo  
Nr albumu: 432511

**Charakterystyka i lokalizacja nieruchomości  
mieszkaniowych, a ich ceny ofertowe - analiza rynku  
warszawskiego na podstawie ofert z serwisu Otodom**

Praca zaliczeniowa  
Ekonometria przestrzenna w R

Praca wykonana pod kierunkiem  
prof. Katarzyny Kopczewskiej  
z Katedry Data Science  
WNE UW

Warszawa, styczeń 2024

## WSTĘP

Nieruchomość to dobro, które wyróżnia się na tle innych ze względu na kluczową rolę jaką odgrywa w życiu ludzkim. Zapewnia ono podstawowe potrzeby ludzkie takie jak schronienie, poczucie bezpieczeństwa i prywatność. Prawie wszystkie mieszkania, bez względu na jego cechy, są w stanie spełnić podstawowe potrzeby ludzkie, a więc konsumenci przy zakupie nieruchomości mieszkaniowych kierują się głównie preferencjami i ograniczeniem budżetowym. Preferencje co do mieszkania dotyczą głównie jego cech fizycznych, w tym lokalizacji. Na kształtowanie się ceny nieruchomości wpływa wiele czynników ekonomicznych, jednak można przekrojowo dokonać wyceny nieruchomości wykorzystując ich cechy charakterystyczne. Dobra heterogeniczne, takie jak nieruchomości, są agregatem cech, które mają swoją hierarchię atrakcyjności i poprzez preferencje wpływają na cenę dobra. Przy pomocy modelu ekonometrycznego można wycenić przybliżoną wartość poszczególnych cech nieruchomości dla konsumentów, dokonując w ten sposób rozwarstwienia ceny dobra na wartość czynników, z których jest zbudowane. Zastosowanie modeli ekonometrycznych na polskim rynku mieszkaniowym wciąż nie zostało szeroko wykorzystane w literaturze, a wyniki prac badawczych z innych krajów nie są przekładalne na nasz rynek, ze względu na brak homogeniczności preferencji konsumentów pomiędzy krajami, a nawet miastami.

Celem pracy jest zbadanie determinantów cen nieruchomości w Warszawie na rynku wtórnym przy pomocy modelu ekonometrycznego, wykorzystując do tego dane ofertowe pozyskane metodą web-scrapingu z serwisu <https://www.otodom.pl/>, ujawniając w ten sposób cechy nieruchomości mieszkaniowych, które w największym stopniu wpływają na cenę jednego metra kwadratowego nieruchomości. Temat pracy jest ważny ze względu na ciągle zmieniający się rynek mieszkaniowy. W 2022 roku wystąpił potężny napływ nowych konsumentów ze wschodnich krajów do Polski, który wpłynął na zmiany preferencji i stworzył zapotrzebowanie na przeprowadzenie aktualnych badań dotyczących atrakcyjności poszczególnych charakterystyk mieszkań na rynku wtórnym w Warszawie. Dodatkowo w ciągu ostatnich lat pandemia, zmienna sytuacja gospodarcza w kraju oraz Bezpieczny Kredyt 2% miał istotny wpływ na kształtowanie się popytu i podaży nieruchomości, a więc liczba oddawanych mieszkań do użytkowania i dostępność kredytów uległa zmianie. Zgodnie z przyjętymi przez autora oczekiwaniami lokalizacja powinna być najważniejszą determinantą ceny nieruchomości, aczkolwiek pogłębiony deficyt mieszkań mógł sprawić, że położenie przestało odgrywać decydującą rolę, a granica cenowa między dzielnicami została rozmyta.

## ROZDZIAŁ I

### Wpływ wybranych cech nieruchomości na cenę – przegląd literatury

#### 1.1. Cechy nieruchomości

Nieruchomości odznaczają się wyjątkowo obszerną specyfiką. Niska porównywalność jednej nieruchomości z innymi, z uwagi na wielość i możliwą różnorodność ich cech, utrudnia określenie jej wartości, a wycena wymaga uwzględnienia szeregu niezależnych czynników. Nieruchomości posiadają szeroki wachlarz właściwości, które można podzielić na różnorodne kategorie, w tym na cechy fizyczne, ekonomiczno-społeczne oraz instytucjonalno-prawne.<sup>1</sup> Cechy te odróżniają nieruchomości od siebie, powodując ich unikatowość.

Można wyróżnić uniwersalne cechy fizyczne charakterystyczne dla wszystkich nieruchomości takie jak stałość w miejscu i trwałość, a także indywidulane właściwości, które powodują ich różnorodność.<sup>2</sup> Na tle innych dóbr, nieruchomość wyróżnia się nieprzenoszalnością. Zarówno ziemia jak i budynek są nieruchome, więc nie ma możliwości przemieszczania jej w korzystniejsze miejsce. Dzięki temu jednak mogła powstać cecha szczególna jaką jest lokalizacja. Istnieje wiele innych fizycznych cech nieruchomości, które są zróżnicowane między nieruchomościami. Każda nieruchomość posiada indywidualny charakter. Nieruchomości mogą różnić się od siebie pod względem położenia, wielkości lub kształtu. Dodatkowo obiekty budowlane odbiegają od siebie zastosowanymi materiałami i projektem. Nawet budynki wybudowane na podstawie identycznego planu, różnią się usytuowaniem w terenie, jakością wykonania czy datą oddania budynku do użytkowania. W przypadku nieruchomości ziemskich dochodzi kwestia warunków gruntowo-wodnych, topografii terenu, jakości gleby i uzbrojenia działki.

Rozważając cechy ekonomiczne nieruchomości powinniśmy wyróżnić rzadkość (i związaną z nią podaż) i zapotrzebowanie (oraz związany z nim popyt). Rzadkość oznacza limitowaną podaż nieruchomości na danym rynku lokalnym. Deficytowość dotyczy szczególnie nieruchomości gruntowych oraz budynkowych w dobrej lokalizacji. Podaż ziemi ustalona jest przez naturę i nie może być dowolnie zmieniana, a powierzchnia terenów miejskich jest ograniczona. Obecnie w miastach liczba nieruchomości budowlanych jest niewystarczająca do spełniania potrzeb mieszkaniowych, jednakże niedobór mieszkań

---

<sup>1</sup> Kucharska-Stasiak, E., 2006, *Nieruchomość w gospodarce rynkowej*, Wydawnictwo Naukowe PWN, s. 17.

<sup>2</sup> Otręba, A., 2005, *Nieruchomości inwestycyjne w ujęciu rachunkowości*, Studia Ekonomiczne/Akademia Ekonomiczna w Katowicach, 33, s. 191-210.

dotyczy głównie krótkiego okresu. W długim okresie podaż nieruchomości stale rośnie, ponadto zgodnie z raportami Banku Światowego oraz ONZ prognozuje się, że liczba ludności w Polsce i polskich miastach będzie maleć<sup>3,4</sup>. Zapotrzebowanie na mieszkania generowane jest głównie przez gospodarstwa domowe potrzebujące nieruchomości do zaspokajania swoich potrzeb bytowych.<sup>5</sup> Na kształtowanie popytu i podaży nieruchomości wpływa wiele czynników o charakterze gospodarczym i społecznym. Do podstawowych czynników popytowo-podażowych cen nieruchomości możemy zaliczyć koszty budowy, dochody gospodarstw domowych, liczebność populacji na danym rynku lokalnym, wskaźnik zatrudnienia i stopy procentowe.<sup>6</sup>

Z nieruchomością wiązą się również jej właściwości instytucjonalno-prawne. Aby nieruchomość mogła funkcjonować, konieczne jest stworzenie kompleksowego systemu prawnego, który będzie regulował cały cykl życia nieruchomości. Rozważając stan prawny nieruchomości można wyróżnić przede wszystkim: rodzaj własności, obciążenia nieruchomości na rzecz osób trzecich, występujące roszczenia lub zapis hipoteki. Teoretycznie stan prawny nieruchomości powinien być ujawniony w księdze wieczystej, aczkolwiek zdarza się, że nie wszystkie wpisy zostały umieszczone lub nieruchomość w ogóle nie ma założonej księgi wieczystej. Dodatkowo, nieruchomości w Polsce objęte są planem zagospodarowania przestrzennego, a istotne zmiany rozplanowania w obrębie nieruchomości mogą wpłynąć na jej unikalność. Warto również wspomnieć o usługach pośrednictwa sprzedaży, które wywierają wpływ na postrzeganie przez klienta sprzedawanej nieruchomości.

## 1.2. Wpływ lokalizacji na cenę mieszkania

Lokalizacja mieszkania jest najważniejszą determinantą jego ceny.<sup>7</sup> Mieszkania na rynkach lokalnych wykazują znaczące różnice w cenie w zależności od położenia. Zazwyczaj im mieszkanie znajduje się w lokalizacji postrzeganej jako bardziej atrakcyjna, tym jest

---

<sup>3</sup> World Bank, 2021, *Demographic Trends and Urbanization*, Washington, DC. Dostęp 12.2023 r. <https://documents1.worldbank.org/curated/en/260581617988607640/pdf/Demographic-Trends-and-Urbanization.pdf>

<sup>4</sup> United Nations, 2019, *World Urbanization Prospects: The 2018 Revision*, Department of Economic and Social Affairs, Population Division, New York: United Nations. Dostęp 12.2023 r. <https://population.un.org/wup/publications/Files/WUP2018-Report.pdf>

<sup>5</sup> Kokot, S., 2019, *Próba oszacowania chłonności rynku mieszkań w Polsce w perspektywie 20 lat*, Mikroekonometria w teorii i praktyce gospodarki nieruchomościami, Difin, s. 23-44.

<sup>6</sup> Kokot, S., 2020, *Socio-economic factors as a criterion for the classification of housing markets in selected cities in Poland*, Real Estate Management and Valuation, 28(3), s. 77-90.

<sup>7</sup> Wiśniewska, M. A., 2011, *Inwestowanie w nieruchomości na rynkach międzynarodowych: analiza komparatywna efektywności*, Wydawnictwo Naukowe PWN, s. 15-23.

droższe. Zgodnie z literaturą przedmiotu, przyczyny dla których lokalizacja mieszkania ma takie ogromne znaczenie to między innymi dostępność komunikacyjna, dostęp do udogodnień i atrakcji, a także położenie w bezpiecznych dzielnicach. Dodatkowo obserwuje się wzrost ceny nieruchomości, gdy znajduje się bliżej parków i lasów, a efekt jest mocniejszy dla terenów zielonych o większej przestrzeni<sup>8</sup>.

Mieszkania położone daleko od centrum miasta zniechęcają do zakupu nie tylko ograniczonym dostępem do atrakcji, ale także podstawowych potrzeb, takich jak sklepy, szkoły lub specjalistyczne miejsca pracy. W swoim badaniu Wiliński i in. wykazali na przykładzie ulicy Puławskiej w Warszawie, że wpływ odległości od centrum na cenę mieszkania jest liniowy, a wzrost odległości o 1 km, powoduje spadek ceny nieruchomości o 260 zł na jednym metrze kwadratowym<sup>9</sup>. Co więcej, według innych badań, mieszkania znajdujące się w centrum dużych miast aprecjonują szybciej niż te znajdujące się w mniej atrakcyjnych lokalizacjach.<sup>10</sup>

Łatwy dostęp do komunikacji miejskiej lub transportu zbiorowego także jest bardzo ważnym czynnikiem podczas wyboru mieszkania. Mieszkania, które nie są dobrze skomunikowane często sprawiają, że posiadanie samochodu staje się niezbędne dla mieszkańców do załatwiania podstawowych potrzeb, co prowadzi do powiększonych kosztów życia o cenę paliwa i eksploatacji pojazdu. Dodatkowo kierowanie pojazdem prowadzi do powstania kosztu alternatywnego ze względu na brak możliwości produktywnego spędzenia czasu w podróży. Nic dziwnego więc, że ograniczona dostępność komunikacyjna wpływa negatywnie na cenę mieszkania. W swoim badaniu dotyczącym związku lokalizacji stacji metra z ceną mieszkań Torzewski oszacował dla Warszawy, że zwiększenie odległości mieszkania od najbliższej stacji metra o 1 km powoduje wzrost jego ceny o 172 zł na jednym metrze kwadratowym<sup>11</sup>.

### 1.3. Wpływ agencji nieruchomości na cenę mieszkania

Agencje nieruchomości pośrednicząc w transakcjach kupna i sprzedaży odgrywają istotną rolę w rynku nieruchomości. Agencje nieruchomości posiadają szeroką wiedzę oraz

---

<sup>8</sup> Melichar, J., Kaprová, K., 2013, *Revealing preferences of Prague's home buyers towards greenery amenities: The empirical evidence of distance-size effect*, Landscape and Urban Planning, 109, s. 56–66.

<sup>9</sup> Wiliński, D., Kraiński, Ł., Wesołowska, K., Duś, M., Marczak, S., 2017, *Wpływ lokalizacji na cenę ofertową nieruchomości na przykładzie ulicy Puławskiej w Warszawie*, Świat Nieruchomości, 101, s. 69-76.

<sup>10</sup> Maloney, M., Rosenthal, S. S., 2022, *Why Do Home Prices Appreciate Faster in City Centers? The Role of Risk-Return Trade-Offs in Real Estate Markets*, Department of Economics, Syracuse University, s. 1.

<sup>11</sup> Torzewski, M., 2016, *Analiza wpływu lokalizacji stacji metra warszawskiego na ceny mieszkań na przykładzie dzielnicy Ursynów w Warszawie*, Studia i Materiały, (1/2016 (20)), s. 145-155.

obszerne bazy danych na temat transakcji rynku nieruchomości, dzięki temu są w stanie trafnie wyceniać mieszkania oraz rozumieją trendy cenowe i preferencje klientów na danym rynku. Przekłada się to na lepsze dopasowanie ofert sprzedaży do popytu i ma wpływ na kształtowanie się równowagi cenowej na rynku. Agencje nieruchomości mogą oddziaływać na cenę mieszkania na wiele sposobów.

Po pierwsze, agencje nieruchomości mogą kształtować popyt na mieszkania poprzez promowanie ofert sprzedaży lub wynajmu.<sup>12</sup> Promocja ofert sprzedaży odbywa się poprzez różne kanały reklamowe, takie jak ogłoszenia w prasie, na stronach internetowych czy w mediach społecznościowych. Działania marketingowe agentów przyciągają klientów, zwiększają popyt na mieszkania i działają cenotwórczo.

Po drugie, agencje nieruchomości stosują marże za swoje usługi pośrednictwa w transakcjach kupna i sprzedaży, co wpływa na kształtowanie się cen. Prowizje od transakcji najczęściej wyrażane są w procentach, a więc agencjom zależy na osiągnięciu jak najwyższej ceny sprzedaży. Zachowania agencji nieruchomości nie są jednak jednorodne we wszystkich miastach, a wysokość prowizji pobieranych od swoich klientów za pośrednictwo zależy od takich czynników jak lokalizacja mieszkania, standard oraz rynek, na którym działa agencja nieruchomości.<sup>13</sup> Natomiast nie wszyscy kupujący tracą na korzystaniu z usług pośrednictwa, osoby w podeszłym wieku często zaniżają wartość własnego mieszkania, przez co zyskują średnio więcej korzystając z usług agencji nieruchomości.

Istnieją też inne czynniki motywujące agentów nieruchomości do sztucznego pompowania cen nieruchomości.<sup>14</sup> Aby spełnić oczekiwania swoich klientów i wyróżnić się wśród konkurencji, agenci są zmotywowani sprzedawać szybko i po jak najwyższych cenach. Dodatkowo z dużym prawdopodobieństwem sami agenci prywatnie inwestują w nieruchomości, a więc zależy im na wzroście wartości własnego kapitału.

#### **1.4. Wpływ roku budowy na cenę mieszkania**

Styl budownictwa i wykorzystywane materiały drastycznie się zmieniły na przełomie lat dziewięćdziesiątych. Za czasów PRL-u bloki budowane były w większości z tzw. wielkiej płyty, czyli gotowych prefabrykatów betonowych. Bloki z wielkiej płyty były budowane

---

<sup>12</sup> Jud, G. D., Frew, J., 1986, *Real estate brokers, housing prices, and the demand for housing*, Urban Studies, 23(1), s. 21-31.

<sup>13</sup> Violand, W., Simon, A., 2007, *Real estate brokers: do they inflate housing prices? The case of France*, Bankers, Markets & Investors, 111, s. 27-41.

<sup>14</sup> Fereidouni, H. G., 2012, *The role of real estate agents on housing prices and rents: the Iranian experience*, International Journal of Housing Markets and Analysis, 5(2), s. 134-144.

masowo według zaledwie kilku projektów, przez co wyglądają one bardzo podobnie w całej Polsce. Ten typ budowy charakteryzował się niską starannością, płyty potrafiły być uszkodzone już w transporcie, a bloki często posiadały błędy budowlane takie jak krzywe ściany lub nierówne kąty. Poza tym istnieją ograniczenia w przeprowadzeniu remontu ze względu na ściany nośne, które dodatkowo łatwo przepuszczają dźwięk. Zdarza się również, że wewnątrz takich bloków znajduje się śmietnik (zsyp), który sprzyja rozwojowi insektów i gryzoni oraz powoduje nieprzyjemny zapach na klatce.

W latach dziewięćdziesiątych, po obaleniu komunizmu w Polsce, zaczęło kwitnąć tak zwane „nowe budownictwo”, które w odróżnieniu od bloków z wielkiej płyty jest murowane, a mieszkania można odtąd kupić na wolnym rynku. Budowanie z cegieł pozwala na zachowanie większej dokładności, a uniwersalność projektowania umożliwia bardziej przemyślany rozkład pomieszczeń i mniejsze zużycie energii potrzebnej do ogrzewania. Dodatkowo nowe osiedla często wyposażone są w parkingi podziemne, których próżno szukać w komunistycznych blokach. Bezpieczeństwo również jest zaletą nowych bloków, które często znajdują się na strzeżonych osiedlach z ochroną i monitoringiem. Niestety wadą tych bloków jest często lokalizacja. Ze względu na brak miejsca na budowę kolejnych budynków w strategicznych miejscach, wiele nowych osiedli powstaje na obrzeżach miast.

Wykres rozrzutu między rokiem budowy, a ceną za m<sup>2</sup> mieszkania w Warszawie przeanalizowany przez Wilińskiego i in. wskazuje na brak liniowej zależności między tymi wielkościami.<sup>15</sup> Można zatem zaobserwować wyraźny podział na dwa przedziały między nowym i komunistycznym budownictwem. Mieszkania z nowego budownictwa tanieją wraz ze wzrostem wieku budynku. Z kolei cena bloków wybudowanych w PRL-u rośnie im blok jest starszy. Wyższa cena mieszkań starych wiekiem może wynikać z przeprowadzonych remontów w tych mieszkaniach. W szczególności istotna może być aktywność tzw. flipperów na rynku nieruchomości, którzy wykupują stare zaniedbane mieszkania o niskiej wartości rynkowej w celu dokonania remontu i sprzedania ich po jak najwyższej cenie. W celu reklamy takich mieszkań wykorzystują oni do tego nowoczesne techniki marketingowe. Czerniak i in. wskazują, że nadmierna aktywność flipperów działa cenotwórczo, a miasta, w których aktywność flipperów jest największa, są równocześnie tymi, gdzie odnotowano najwyższy wzrost cen nieruchomości między końcem 2016 r., a końcem 2020 r.<sup>16</sup> Flipperzy sprzedają mieszkania powyżej ceny równowagi rynkowej, a gdy jest ich zbyt wielu -

---

<sup>15</sup> Wiliński, D., Kraiński, Ł., Wesołowska, K., Duś, M., Marczak, S., 2017, op. cit.

<sup>16</sup> Czerniak, A., Milewska-Wilk, H., Bojć, T., 2021, *Zjawisko flippingu na polskim rynku mieszkaniowym*, Studia BAS, 2(66), s. 195-213.

wywierają wpływ na postrzeganie wartości rynkowej nieruchomości wśród innych sprzedawców.

### 1.5. Wpływ piętra na cenę mieszkania

Wpływ piętra na cenę mieszkania nie został jak dotąd szeroko opisany w polskiej literaturze. Przy budowaniu hedonicznych modeli cen mieszkań zwykle nie przykładano zbyt dużej uwagi do zmiennej określającej piętro. Zmienna ta zazwyczaj jest wykorzystywana jako zmienna kontrolna. Jednakże wraz ze wzrostem gęstości zaludnienia w dużych miastach i rosnącą popularnością wysokiego budownictwa, piętro może okazać się istotnym czynnikiem dla klienta podczas zakupu mieszkania. Niestety prace badawcze poruszające szerzej wpływ piętra na cenę nieruchomości dotyczą najczęściej gęsto zaludnionych miast w Chinach, gdzie budynki mieszkalne liczą kilkadziesiąt pięter. Zdaniem Xiao i in. wpływ poziomu piętra na cenę nie jest liniowy i różni się w zależności od lokalizacji mieszkania oraz typów budynków, różnicowanych względem wysokości.<sup>17</sup> Zdaniem wspomnianych badaczy najbardziej atrakcyjne piętra to te, które znajdują się mniej więcej na środku budynku. Dużą rolę odgrywają widoki krajobrazowe, które zazwyczaj różnią się w zależności od piętra i lokalizacji. Istnieją także różne inne powody, dla których klienci preferują pewne poziomy pięter. Czynniki zewnętrzne, takie jak hałas uliczny i zanieczyszczenie powietrza, w różnym stopniu oddziałują na mieszkańców w zależności od piętra, na którym znajduje się nieruchomość.<sup>18</sup> Niektórzy kupujący kierują się również przesadami dotyczącymi konkretnych liczb przy wyborze numeru piętra.<sup>19</sup> Dodatkowo wysokie piętra mogą być nieatrakcyjne ze względu na długi czas podróży windą do mieszkania oraz ograniczone bezpieczeństwo podczas wybuchu pożaru w budynku.

---

<sup>17</sup> Xiao, Y., Hui, E. C., Wen, H., 2019, *Effects of floor level and landscape proximity on housing price: A hedonic analysis in Hangzhou*, Habitat International, China, 87, s. 11-26.

<sup>18</sup> Wen, H., Gui, Z., Zhang, L., Hui, E. C., 2020, *An empirical study of the impact of vehicular traffic and floor level on property price*, Habitat international, 97, 102132, s. 8.

<sup>19</sup> Humphreys, B. R., Nowak, A., Zhou, Y., 2019, *Superstition and real estate prices: Transaction-level evidence from the US housing market*, Applied Economics, 51(26), s. 2818-2841.



## ROZDZIAŁ II

### Zastosowanie modelu ekonometrycznego celem dekompozycji cen nieruchomości mieszkaniowych

#### 2.1 Zbiór danych i zmienne wykorzystane w badaniu

Aby dokonać przekrojowej analizy determinantów cen nieruchomości mieszkaniowych, wykorzystano dane ze strony <https://otodom.pl>, która jest jednym z największych serwisów ogłoszeniowych nieruchomości w Polsce. Ogłoszenia na Otodom.pl zawierają ceny ofertowe oraz wiele informacji dotyczących charakterystyk nieruchomości. Na potrzeby badania wykonanego w niniejszej pracy dane zostały pozyskane z wykorzystaniem metody web-scrapingu w dniu 15.12.2023 r. Uzyskane dane po ograniczeniach zawierają 3213 pozycji. Na początku dane zostały ograniczone do mieszkań na rynku wtórnym. Następnie, w przypadku zmiennej dotyczącej statusu prawnego własności, usunięto wszystkie obserwacje dotyczące mieszkań współdzielonych ze względu na niewielką liczbę obserwacji, tym samym pozostawiając jedynie następujące formy własności: „spółdzielcze własnościowe” i „pełna własność”. Brakujące dane dotyczące własności zostały uzupełnione jako „pełna własność”, jeżeli budynek został wybudowany po 2007 roku. Wynika to z tego, że od 2007 r. przepisy zabraniają ustanawiania własnościowego prawa spółdzielczego do lokalu.<sup>20</sup> Pozostałe wybrakowane dane zostały również usunięte. W modelu bazowym wykorzystano cenę ofertową jako zmienną zależną i 13 zmiennych niezależnych, co ilustruje zamieszczona dalej Tabela 1. Zmienne określające odległości od centrum i od metra zostały obliczone z wykorzystaniem współrzędnych geograficznych odzwierciedlając najkrótszą drogę biegnącą po powierzchni sferycznego modelu ziemi. Promień kuli założony w obliczeniach wynosi 6371.009 km, a więc tyle co średni promień planety według standardu WGS-84<sup>21</sup>. Współrzędne mieszkań zostały zebrane z map zawartych w ogłoszeniach. Za punkt określający centrum ustanowiono Pałac Kultury i Nauki, którego współrzędne, wraz ze współrzędnymi stacji metra, pochodzą z Google Maps.

---

<sup>20</sup> Ustawa z dnia 14 czerwca 2007 r. - o zmianie ustawy o spółdzielniach mieszkaniowych oraz o zmianie niektórych innych ustaw (Dz. U. 2007 nr 125 poz. 873).

<sup>21</sup> National Geospatial-Intelligence Agency (NGA) Standardization Document, 2014, *Department of Defense World Geodetic System 1984: Its Definition and Relationships with Local Geodetic Systems*. Dostęp 12.2023 r. <https://nsgreg.nga.mil/doc/view?i=4085>

Tabela 1. Opis zmiennych wykorzystanych w modelu

Nazwa zmiennej	Objaśnienie	Miara	Typ zmiennej: dyskretna / ciągła / binarna
<i>cena_m2</i>	Cena ofertowa mieszkania za m <sup>2</sup>	PLN	Ciągła
<i>wiek_budynku</i>	Wiek budynku wyrażony w latach	Lata	Dyskretna
<i>powierzchnia</i>	Powierzchnia użytkowa mieszkania	Metry kwadratowe	Ciągła
<i>pietro</i>	Piętro, na którym znajduje się mieszkanie	Liczba	Dyskretna
<i>pietro_max</i>	Wysokość budynku liczona w piętrach	Liczba	Dyskretna
<i>odleglosc_metro</i>	Odległość mieszkania od najbliższej stacji metra	Kilometry	Ciągła
<i>odleglosc_centrum</i>	Odległość mieszkania od Pałacu Kultury i Nauki	Kilometry	Ciągła
<i>agencja</i>	Zmienna określająca czy ogłoszenie zostało wystawione przez agencję nieruchomości	0 – osoba prywatna 1 – agencja nieruchomości	Binarna
<i>balkon</i>	Zmienna określająca czy mieszkanie zawiera balkon	0 – nie 1 – tak	Binarna
<i>winda</i>	Zmienna określająca czy budynek jest wyposażony w windę	0 – nie 1 – tak	Binarna
<i>spoldzielcze</i>	Zmienna określająca czy jest to mieszkanie spółdzielcze własnościowe	0 – pełna własność 1 – spółdzielcze własnościowe	Binarna
<i>remont</i>	Zmienna określająca czy mieszkanie wymaga remontu	0 – nie 1 – tak	Binarna
<i>wykonczenie</i>	Zmienna określająca czy mieszkanie wymaga wykończenia	0 – nie 1 – tak	Binarna
<i>taras</i>	Zmienna określająca czy mieszkanie zawiera taras	0 – nie 1 – tak	Binarna

Źródło: Opracowanie własne na podstawie danych z <https://otodom.pl>.

Obszar badań niniejszej pracy obejmuje miasto stołeczne Warszawa, czyli największe miasto w Polsce zarówno pod względem populacji jak i przestrzeni miejskiej, którego powierzchnia jest równa 51 720 ha, a liczba mieszkańców dnia 1 stycznia 2023 r. wyniosła 1

861 975.<sup>22</sup> Warszawski rynek nieruchomości uznawany jest za wyjątkowo atrakcyjny, a średnie ceny transakcyjne mieszkań zarówno na rynku pierwotnym, jak i wtórnym, są najwyższe w kraju.<sup>23</sup> Miasto stołeczne dzieli się na 18 dzielnic, gdzie najdroższą dzielnicą jest Śródmieście ze średnią ceną ofertową wynoszącą 21 262 zł za m<sup>2</sup> mieszkania, a najtańszą Wawer ze średnią ceną 11 091 zł w III kwartale 2023 r.<sup>24</sup>

W stolicy kluczową rolę w rozwoju rynku nieruchomości stanowią czynniki demograficzne, dobrze rozwinięty rynek pracy i wysokie zarobki. Według GUS, Warszawa jest miastem charakteryzującym się największym wskaźnikiem gęstości zaludnienia w Polsce.<sup>25</sup> Dodatkowo w marcu 2022 r. wystąpił nagły napływ uchodźców z Ukrainy wskutek wojny, który przyczynił się w ciągu jednego miesiąca do spadku liczby ofert wynajmu w Warszawie o 60% i wzrostu cen najmu o 18%.<sup>26</sup> W trakcie 2022 roku, 1 508 338 uchodźców z Ukrainy złożyło wnioski o wydanie numeru PESEL w Polsce.<sup>27</sup> W I kwartale 2023 r. w Warszawie znajdowało się powyżej 100 tys. obywateli Ukrainy.<sup>28</sup> Przyrost ludności kreuje popyt na mieszkania, zwłaszcza kiedy wynika z migracji osób celem podjęcia pracy lub nauki. Warszawa jest centrum naukowym i gospodarczym naszego kraju, dlatego charakteryzuje koncentracją ludności. W 2019 r. w stolicy znajdowało się najwięcej studentów w Polsce, co przełożyło się na drugie miejsce wśród europejskich miast, zaraz za Paryżem, pod względem liczby studentów.<sup>29</sup>

Na zamieszczonym dalej Rys. 1 przedstawiono lokalizację obserwacji na mapie Warszawy. Gradacja kolorów odzwierciedla kolejne kwartyle cen nieruchomości. Zdecydowana większość obserwacji znajduje się po lewej stronie Wisły. Ceny mieszkań w dzielnicach po prawej stronie Wisły są zauważalnie niższe. Najdroższe mieszkania wydają się

---

<sup>22</sup> GUS, 2023, *Powierzchnia i ludność w przekroju terytorialnym w 2023 roku*. Dostęp 12.2023 r.

<sup>23</sup> NBP, 2022, *Informacja o cenach mieszkań i sytuacji na rynku nieruchomości mieszkaniowych i komercyjnych w Polsce w III kwartale 2022 r.* Dostęp 12.2023 r.

[https://nbp.pl/wp-content/uploads/2022/12/ceny\\_mieszkan\\_09\\_2022.pdf](https://nbp.pl/wp-content/uploads/2022/12/ceny_mieszkan_09_2022.pdf)

<sup>24</sup> Tęczak, E., 2023, *Dane Otodom Analytics: ceny mieszkań w 5 największych miastach z podziałem na dzielnice*. Dostęp 12.2023 r.

<https://www.otodom.pl/wiadomosci/dane/otodom-analytics/dane-otodom-aktualne-ceny-ofertowe-w-dzielnicach>

<sup>25</sup> GUS, 2023, *Powierzchnia i ludność w przekroju terytorialnym w 2023 roku*. Dostęp 12.2023 r.

<sup>26</sup> Grupa PKO Banku Polskiego, 2022, *Puls Nieruchomości: Szok na rynku najmu*. Dostęp 12.2023 r.

<https://www.pkobp.pl/centrum-analiz/nieruchomosci/nieruchomosci-mieszkaniowe/puls-nieruchomosci-szok-na-ryнку-najmu/>

<sup>27</sup> UNHCR, 2023, *Ukraine Situation - 2022 Final Report Regional Refugee Response Plan*. Dostęp 12.2023 r.

<https://data.unhcr.org/en/documents/download/99791>

<sup>28</sup> Kancelaria Prezesa Rady Ministrów, 2023, *Szczegółowe statystyki dot. osób zarejestrowanych w rejestrze obywateli Ukrainy i członków ich rodzin, którym nadano status cudzoziemca na podstawie specustawy*. Dostęp 12.2023 r.

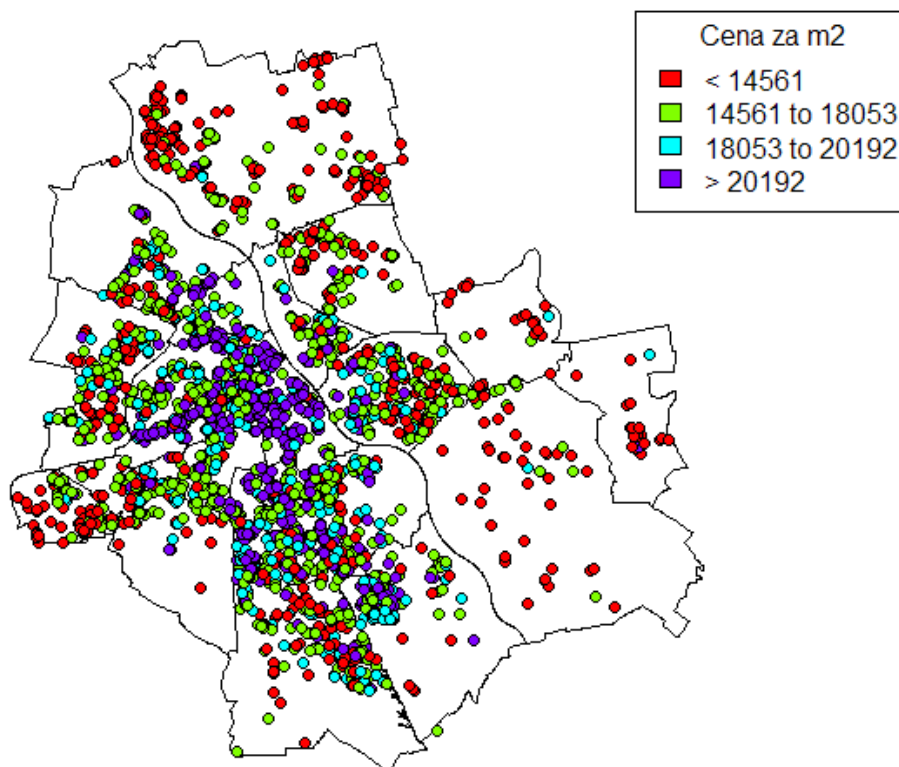
<https://dane.gov.pl/pl/dataset/2715.zarejestrowane-wnioski-o-nadanie-statusu-ukr/resource/46612/table>

<sup>29</sup> Polski Instytut Ekonomiczny, 2019, *Akademickość polskich miast*. Dostęp 12.2023 r.

[https://pie.net.pl/wp-content/uploads/2019/06/PIE-Raport\\_Akademickosc-red..pdf](https://pie.net.pl/wp-content/uploads/2019/06/PIE-Raport_Akademickosc-red..pdf)

być rozmieszczone wzdłuż pierwszej linii metra. Niewiele obserwacji znalazło się w dzielnicach: Wawer, Rembertów oraz Wesoła. Wynika to głównie z popularności domów w tamtym regionie. W przypadku Białołęki i Wilanowa osiedla bloków mieszkaniowych zgrupowane są raczej na konkretnych obszarach tych dzielnic.

Rys. 1. Rozmieszczenie obserwacji i ich cen na mapie Warszawy



Źródło: Opracowanie własne na podstawie danych z: <https://www.otodom.pl/>

Dokładne statystyki opisowe zmiennych przedstawiono w Tabeli 2. Nieruchomości w stolicy są wyjątkowo drogie, średnia cena ofertowa za m<sup>2</sup> w badanej próbie wyniosła aż 18053,28 zł. Dodatkowo mieszkania w Warszawie nie są zbyt duże, ponieważ średnia powierzchnia użytkowa wyniosła 66.19 m<sup>2</sup>, a najmniejsze mieszkanie ma tylko 11,28 m<sup>2</sup>. Obecnie zgodnie z polskim prawem mieszkanie powinno mieć powierzchnię użytkową nie mniejszą niż 25 m<sup>2</sup>, aczkolwiek przed 2018 r. zapis ten nie był tak restrykcyjny, a także można dalej go obejść sprzedając mieszkanie jako lokal użytkowy.<sup>30</sup> Linie metra wydają się być dobrze zoptymalizowane, ponieważ średnia odległość nieruchomości od najbliższej stacji metra wynosi zaledwie 2,34 km. Większość mieszkań wyposażona jest w balkon (65.70%) oraz windę (69.65%), aczkolwiek taras przylega tylko do 15.66% z nich. Niewiele nieruchomości jest w drugorzędnym stanie, ponieważ tylko 8.71% z nich wymaga remontu, a

<sup>30</sup> Rozporządzenie Ministra Infrastruktury z dnia 12 kwietnia 2002 r. - w sprawie warunków technicznych, jakim powinny odpowiadać budynki i ich usytuowanie (Dz.U. 2022 poz. 1225).

wykończenia potrzebuje 9.55%. Zaskakująco dużo mieszkań sprzedawanych jest przez agencje nieruchomości, gdyż wskaźnik ten wyniósł w badanej próbie 76.53%.

*Tabela 2. Statystyki opisowe zmiennych wykorzystanych w modelu*

Nazwa zmiennej	Średnia	Odchylenie standardowe	Minimum	Maksimum
cena_m2	18053,28167	5321,384233	4821	50595
powierzchnia	66,187893	38,829953	11,28	487,75
wiek_budynku	1998,792406	22,985718	1944	2023
pietro	2,838469	2,341565	0	10
pietro_max	5,833126	3,313799	1	30
winda	0,696545	0,459821	0	1
balkon	0,657018	0,474779	0	1
taras	0,156552	0,363434	0	1
odleglosc_metro	2,344504	2,137635	0,023278	14,459002
odleglosc_centrum	6,382423	3,23092	0,189656	16,683793
agencja	0,765328	0,423859	0	1
spoldzielcze	0,101463	0,301988	0	1
remont	0,087146	0,282093	0	1
wykonczenie	0,095549	0,294018	0	1

Źródło: Opracowanie własne na podstawie danych z: <https://www.otodom.pl/>

## 2.2. Badanie empiryczne

Aby zbadać w jakim stopniu konkretne cechy i usytuowanie mieszkania wpływają na jego cenę, posłużono się modelem GWR. Metoda regresji ważonej geograficznie została opracowana w celu uwzględnienia zróżnicowanego wpływu zmiennych w przestrzeni oraz występowania dryfu przestrzennego. Pozwala ona na uzyskanie indywidualnych współczynników dla każdej obserwacji. Ważne jednak jest to, że GWR nie analizuje bezpośrednio podobieństwa przestrzennego między zmiennymi, czyli autokorelacji przestrzennej. Można jednak uwzględnić obydwa efekty metodą zaproponowaną przez Müllera<sup>31</sup>, dokonując klastrowania podobnych obserwacji względem współczynników GWR metodą k-średnich, a następnie wykorzystując przynależność do klastrów pod postacią zmiennych binarnych w innym modelu przestrzennym. Na samym początku jednak został wyestymowany podstawowy model regresji liniowej Metodą Najmniejszych Kwadratów, aby porównać skuteczność bardziej zaawansowanych modeli (Rys. 1). Postać równania wykorzystana w badaniu jest równa:

<sup>31</sup> Müller, S., Wilhelm, P., & Haase, K. (2013). Spatial dependencies and spatial drift in public transport seasonal ticket revenue data. *Journal of Retailing and Consumer Services*, 20(3), 334-348.

$$\ln(cena\_m2_i) = \beta_0 + \beta_1 \text{wiek\_budynku} + \beta_2 \text{winda}_i + \beta_3 \text{powierzchnia}_i + \beta_4 \text{pietro}_i + \beta_5 \text{pietro\_max}_i + \beta_6 \text{balkon}_i + \beta_7 \text{odleglosc\_metro}_i + \beta_8 \text{odleglosc\_centrum}_i + \beta_9 \text{agencja}_i + \beta_{10} \text{spoldzielcze}_i + \beta_{11} \text{remont}_i + \beta_{12} \text{wykonczenie}_i + \beta_{13} \text{taras}_i + \epsilon_i,$$

Rys. 1. Wyniki estymacji regresji liniowej

```

Residuals:
    Min       1Q   Median       3Q      Max
-1.10954 -0.12474 -0.00703  0.11588  0.89607

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  10.20743642  0.01875716  544.189 < 0.0000000000000002 ***
remont       -0.14314969  0.01350993 -10.596 < 0.0000000000000002 ***
wykonczenie -0.09244742  0.01236244  -7.478  0.0000000000000968 ***
winda        0.05370079  0.00891169   6.026  0.0000000018734284 ***
balkon       -0.03934228  0.00811203  -4.850  0.0000012944146391 ***
taras        0.03842970  0.01073883   3.579    0.000351 ***
wiek_budynku -0.00306956  0.00021319 -14.398 < 0.0000000000000002 ***
spoldzielcze -0.09451471  0.01278858  -7.391  0.0000000000001857 ***
powierzchnia -0.00018757  0.00009833  -1.908    0.056530 .
pietro       -0.00200722  0.00163368  -1.229    0.219295
pietro_max   -0.00006777  0.00010035  -0.675    0.499517
odleglosc_metro -0.02557778  0.00220213 -11.615 < 0.0000000000000002 ***
odleglosc_centrum -0.04199337  0.00155043 -27.085 < 0.0000000000000002 ***
agencja      -0.01358504  0.00865705  -1.569    0.116689

---Significance stars
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
Residual standard error: 0.2024 on 3199 degrees of freedom
Multiple R-squared:  0.4491
Adjusted R-squared:  0.4469
F-statistic: 200.6 on 13 and 3199 DF,  p-value: < 0.00000000000000022
***Extra Diagnostic information
Residual sum of squares: 131.0554
sigma(hat): 0.202026
AIC: -1131.38
AICC: -1131.23
BIC: -4132.132

```

Źródło: Opracowanie własne w R

Wyniki testów na modelu bazowym liniowym okazały się niezadowalające, gdyż model nie spełnił podstawowego kryterium dotyczącego liniowości, nie wykazał homoskedastyczności składnika losowego, a dopasowanie modelu nie jest zbyt wysokie ( $R^2 = 44,91\%$ ). Co więcej, trzy zmienne wykazują brak istotności statystycznej. Nie należy jednak skupiać się na tym modelu, ponieważ zmienne prawdopodobnie są przestrzennie heterogeniczne, co prowadzi do wzrostu wariancji oszacowań parametrów, która to może wpływać na ich brak istotności. Mimo uwzględnienia dwóch zmiennych lokalizacyjnych, nie



jest to wystarczające pokrycie wpływu lokalizacji oraz pominięty zostaje efekt oddziaływania na siebie blisko położonych obserwacji.

Rys. 2. Wyniki estymacji modelu GWR

```
*****Model calibration information*****
kernel function: gaussian
Fixed bandwidth: 0.3945655
Regression points: the same locations as observations are used.
Distance metric: A distance matrix is specified for this model calibration.

*****Summary of GWR coefficient estimates:*****
               Min.      1st Qu.      Median      3rd Qu.      Max.
Intercept    10.199395672 10.208770711 10.211333690 10.213879045 10.2174
remont       -0.145955073 -0.143674272 -0.142944434 -0.142250702 -0.1412
wykonczenie -0.093640005 -0.092834692 -0.092489631 -0.092172870 -0.0916
winda        0.050424786  0.051787106  0.052787033  0.053746028  0.0575
balkon       -0.040913324 -0.039519168 -0.039170573 -0.038809061 -0.0382
taras        0.037834920  0.038520521  0.038933579  0.039307634  0.0404
wiek_budynku -0.003138319 -0.003110959 -0.003095276 -0.003079798 -0.0030
spoldzielcze -0.095698716 -0.095078780 -0.094818498 -0.094568741 -0.0937
powierzchnia -0.000194655 -0.000183719 -0.000179897 -0.000175361 -0.0002
pietro       -0.002184703 -0.002140057 -0.002124659 -0.002103554 -0.0020
pietro_max   -0.000070885 -0.000069351 -0.000068690 -0.000068214 -0.0001
odleglosc_metro -0.027669499 -0.026758942 -0.026427365 -0.026124820 -0.0245
odleglosc_centrum -0.043191501 -0.042473154 -0.042246474 -0.041905200 -0.0410
agencja      -0.013814603 -0.013554282 -0.013434565 -0.013319928 -0.0128
*****Diagnostic information*****
Number of data points: 3213
Effective number of parameters (2*trace(S) - trace(S'S)): 15.14761
Effective degrees of freedom (n-2*trace(S) + trace(S'S)): 3197.852
AICC (GWR book, Fotheringham, et al. 2002, p. 61, eq 2.33): -1158.804
AIC (GWR book, Fotheringham, et al. 2002, GWR p. 96, eq. 4.22): -1175.553
BIC (GWR book, Fotheringham, et al. 2002, GWR p. 61, eq. 2.34): -4285.35
Residual sum of squares: 129.8876
R-square value: 0.4540452
Adjusted R-square value: 0.4514583
```

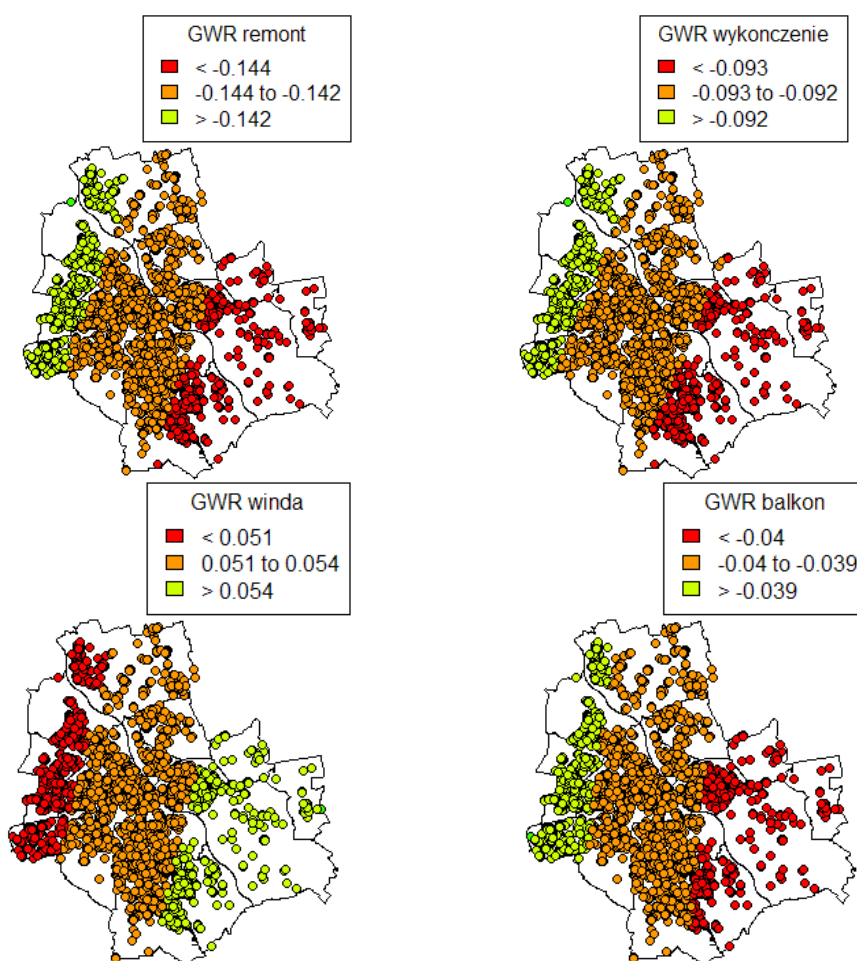
Źródło: Opracowanie własne w R

W kolejnym etapie analizy, mającej na celu zrozumienie wpływu dryfu przestrzennego na cenę nieruchomości w Warszawie, skonstruowano model GWR o takiej samej postaci jak oszacowany model liniowy, czyli uwzględniający wszystkie zmienne zależne w formie bazowej i cenę w postaci logarytmicznej. Najpierw zasymulowano optymalną szerokość pasma, która określa zakres, w jakim sąsiednie obserwacje są brane pod uwagę przy obliczaniu współczynników regresji dla danego punktu w przestrzeni. Wyliczona szerokość pasma metodą walidacji krzyżowej, polegająca na minimalizacji RMSE przy zastosowaniu globalnego podejścia do wymiaru przestrzennego wyniosła 0,3949375. W trakcie analizy modelu GWR otrzymano zakresy zmienności współczynników zmiennych niezależnych (Rys.

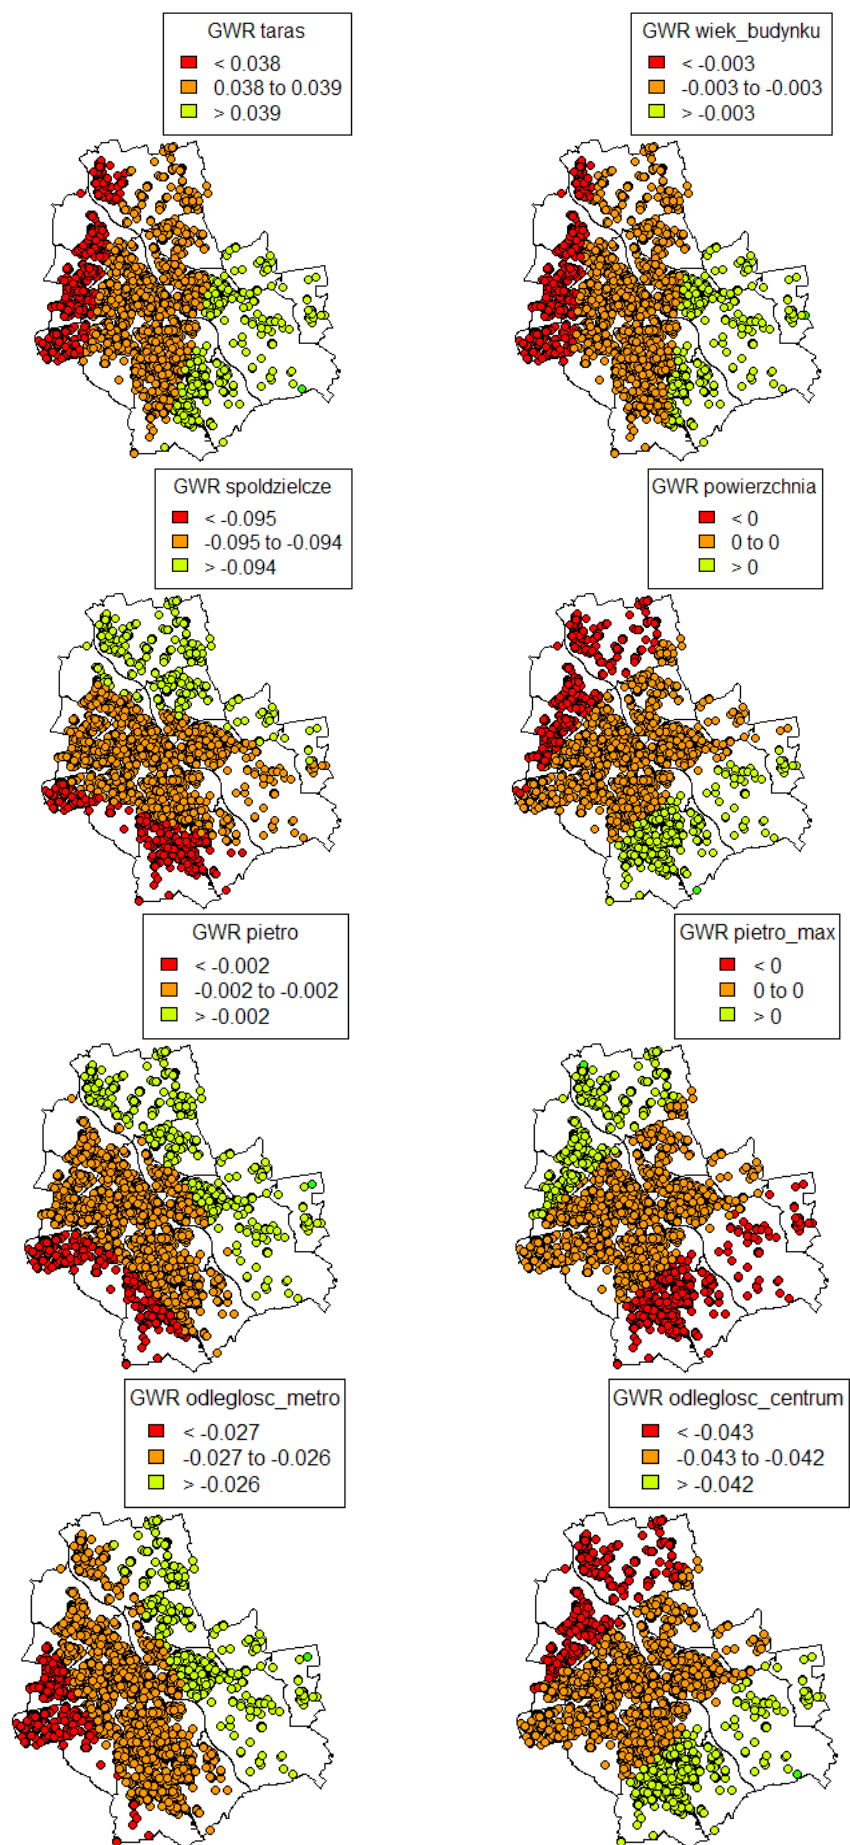
2). Poziom zmienności współczynników z regresji nie jest zbyt duży, co oznacza relatywnie stały efekt poszczególnych zmiennych zależnych w przestrzeni. Dodatkowo wszystkie zmienne przyjmują konsekwentnie współczynniki ujemne lub dodatnie dla każdej z obserwacji, co może wskazywać na dobrą jakość danych. Jakość modelu GWR jest nieznacznie lepsza niż w KMRL na co wskazują niższe wartości kryteriów informacyjnych AIC oraz BIC, a także wyższy współczynnik dopasowania modelu  $R^2$ .

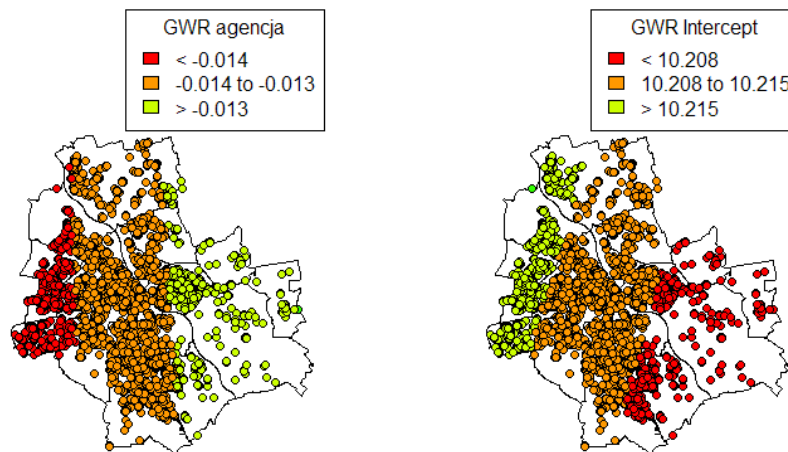
Zróźnicowanie przestrzenne współczynników regresji GWR zostało zwizualizowane na Rys. 3. Dla każdej zmiennej widać wyraźny podział na trzy równoległe sektory w kształcie linii prostej. Zastosowanie modelu jest więc adekwatne, ponieważ wysokość współczynników jest ściśle powiązana z danym obszarem, a przedziały zmiennej są wyraźnie odseparowane i nie nachodzą na siebie.

Rys. 3. Zróźnicowanie przestrzenne współczynników zmiennych w modelu GWR










Źródło: Opracowanie własne w R

W następnym kroku, opierając się na podejściu zaproponowanym przez Müllera<sup>32</sup>, przeprowadzono klastrowanie współczynników uzyskanych z regresji GWR za pomocą metody „kmeans”, aby odnaleźć tendencje do grupowego występowania podobnych efektów na cenę w konkretnych lokalizacjach. Przy klastrowaniu obserwacji uwzględniane są wszystkie współczynniki GWR jednocześnie, ponieważ zmienne oddziałują na siebie nawzajem. Wykonano wykres statystyki silhouette dla poszczególnej liczby klastrów (Rys. 4). Najwyższa wartość osiągana jest dla  $k=8$ , a model ten daje najlepsze wyniki, dlatego zdecydowano, że optymalna liczba klastrów powinna wynieść  $k=8$ . Warszawa jest zróżnicowanym miastem, a więc mnoga liczba klastrów wydaje się odpowiednio odzwierciedlać jego złożoność.

<sup>32</sup> Müller, S., Wilhelm, P., & Haase, K. (2013). Spatial dependencies and spatial drift in public transport seasonal ticket revenue data. *Journal of Retailing and Consumer Services*, 20(3), 334-348.

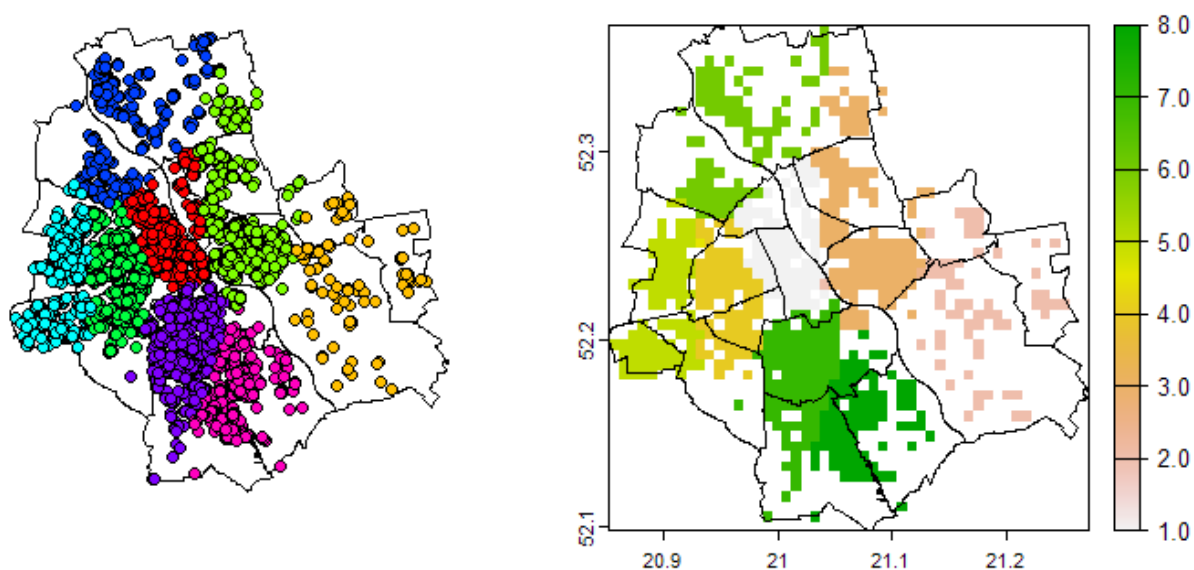
Rys. 4. Wartość statystyki silhouette dla poszczególnej liczby klastrów



Źródło: Opracowanie własne w R

Zwizualizowano podział obserwacji na klastry i rastry na mapie Warszawy (Rys. 5). Jak można zauważyć, uzyskano wyraźnie zdefiniowane klastry o odrębnych obszarach przestrzennych.

Rys. 5. Podział obserwacji na klastry i rastry na mapie Warszawy



Źródło: Opracowanie własne w R

Ostatnim krokiem w modelowaniu dryfu przestrzennego jest oszacowanie modelu heterogenicznego przestrzennie, który uwzględnia wcześniej utworzone zmienne binarne, informujące o przynależności obserwacji do konkretnych klastrów. Celem analizy jest zweryfikowanie czy podział na klastry ma znaczenie dla uzyskanych wyników, tym samym potwierdzając obecność dryfu przestrzennego. Obecność w klastrze ósmym oznacza poziom bazowy.

Rys. 6. Wyniki estymacji modelu a-przestrzennego

```

Residuals:
    Min       1Q   Median       3Q      Max
-0.95520 -0.11239 -0.00485  0.10151  0.93555

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  10.45921027  0.02688032  389.103 < 0.0000000000000002 ***
remont       -0.13626807  0.01250579  -10.896 < 0.0000000000000002 ***
wykonczenie -0.08180383  0.01148898   -7.120  0.0000000000013256 ***
winda        0.04335458  0.00831663    5.213  0.0000001976336008 ***
balcon       -0.02725749  0.00752534   -3.622   0.000297 ***
taras        0.03490288  0.00994953    3.508   0.000458 ***
wiek_budynku -0.00368554  0.00020134  -18.305 < 0.0000000000000002 ***
spoldzielcze -0.09003203  0.01185232   -7.596  0.0000000000000398 ***
powierzchnia -0.00061293  0.00009335   -6.566  0.0000000000600285 ***
pietro       -0.00061397  0.00151893   -0.404   0.686084
pietro_max   -0.00007265  0.00009288   -0.782   0.434158
odleglosc_metro -0.01239287  0.00266510   -4.650  0.0000034530820299 ***
odleglosc_centrum -0.05341080  0.00218723  -24.419 < 0.0000000000000002 ***
agencja      -0.02681005  0.00805222   -3.330   0.000880 ***
klaster1     -0.11388351  0.01899356   -5.996  0.0000000022498998 ***
klaster2     -0.11770503  0.02648851   -4.444  0.0000091463535883 ***
klaster3     -0.26989081  0.01517940  -17.780 < 0.0000000000000002 ***
klaster4     -0.21569329  0.01714092  -12.584 < 0.0000000000000002 ***
klaster5     -0.25554245  0.01476402  -17.308 < 0.0000000000000002 ***
klaster6     -0.17494086  0.01422988  -12.294 < 0.0000000000000002 ***
klaster7     -0.12777635  0.01446109   -8.836 < 0.0000000000000002 ***

---Significance stars
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
Residual standard error: 0.1872 on 3192 degrees of freedom
Multiple R-squared:  0.53
Adjusted R-squared:  0.527
F-statistic:  180 on 20 and 3192 DF,  p-value: < 0.0000000000000022
***Extra Diagnostic information
Residual sum of squares: 111.8208
Sigma(hat): 0.1866127
AIC: -1627.356
AICC: -1627.039
BIC: -4529.058

```

Źródło: Opracowanie własne w R

Dokonano estymacji modelu a-przestrzennego (Rys. 6). Model ten jest zdecydowanie lepszy od bazowego, gdyż jego wartości kryteriów informacyjnych są istotnie niższe, a po uwzględnieniu dryfu przestrzennego zmienna agencja stała się istotna. Wszystkie zmienne, poza dotyczącymi piętra, są istotne na poziomie 1%. Istotność klastrów potwierdziła słuszność modelowania dryfu przestrzennego.

Aby sprawdzić czy efekt autokorelacji przestrzennej i dryfu przestrzennego występuje jednocześnie dokonano estymacji modelu błędu przestrzennego uwzględniającego klastry współczynników GWR (Rys. 7). Model błędu przestrzennego wpłynął na uzyskanie istotności przez zmienną *pietro*, jednocześnie nie zmieniając znaczenia statystycznego pozostałych zmiennych, które dalej są istotne na poziomie 1%. Dodatkowo wartość lambda jest istotna statystycznie, co oznacza, że efekty przestrzenne nie zostały odfiltrowane przez klastry. Model ten przewyższa pozostałe badane modele dzięki uwzględnieniu największej ilości zmiennych oraz uzyskaniu najlepszych wartości kryteriów informacyjnych. Można więc stwierdzić, że na rynku nieruchomości występuje zarówno lokalne zróżnicowanie efektów, jaki i podobieństwo obserwacji w najbliższym sąsiedztwie. Właściwą metodą modelowania cen nieruchomości będzie zastosowanie podejścia Müllera.

Rys. 7. Wyniki estymacji modelu błędu przestrzennego

```

Residuals:
    Min       1Q   Median       3Q      Max
-0.8754154 -0.0980045 -0.0067271  0.0924812  0.8995295

Type: error
Coefficients: (asymptotic standard errors)
            Estimate Std. Error z value Pr(>|z|)
(Intercept)  10.462053725  0.037185646 281.3466 < 0.00000000000000022
remont       -0.125746135  0.011215785 -11.2115 < 0.00000000000000022
wykonczenie -0.096886590  0.010827553  -8.9482 < 0.00000000000000022
winda        0.035399520  0.007724215   4.5829  0.00000458510978163
balkon       -0.020664778  0.006852950  -3.0155    0.0025659
taras        0.040911739  0.008971192   4.5603  0.00000510694060507
wiek_budynku -0.004163104  0.000209432 -19.8780 < 0.00000000000000022
spoldzielcze -0.086366944  0.011374820  -7.5928  0.000000000000003131
powierzchnia -0.000971466  0.000090088 -10.7836 < 0.00000000000000022
pietro        0.003060073  0.001412921   2.1658    0.0303282
pietro_max   -0.000075572  0.000082999  -0.9105    0.3625506
odleglosc_metro -0.012282298  0.004570222  -2.6875    0.0071997
odleglosc_centrum -0.051253898  0.003539338 -14.4812 < 0.00000000000000022
agencja      -0.026352259  0.007228840  -3.6454    0.0002669
klaster1     -0.097867325  0.030701548  -3.1877    0.0014341
klaster2     -0.119639504  0.045233999  -2.6449    0.0081715
klaster3     -0.255425400  0.025401172 -10.0557 < 0.00000000000000022
klaster4     -0.207516178  0.028037736  -7.4013  0.00000000000013478
klaster5     -0.255205920  0.025010728 -10.2039 < 0.00000000000000022
klaster6     -0.185249694  0.024130066  -7.6771  0.0000000000001621
klaster7     -0.113588626  0.023974927  -4.7378  0.00000216041236745

Lambda: 0.49029, LR test value: 463.08, p-value: < 0.00000000000000022
Asymptotic standard error: 0.020427
      z-value: 24.002, p-value: < 0.00000000000000022
wald statistic: 576.1, p-value: < 0.00000000000000022

Log likelihood: 1067.22 for error model
ML residual variance (sigma squared): 0.028719, (sigma: 0.16947)
Number of observations: 3213
Number of parameters estimated: 23
AIC: -2088.4, (AIC for lm: -1627.4)

```

Źródło: Opracowanie własne w R

### 3.3. Wnioski

Przeprowadzone badanie miało na celu przeanalizowanie jak poszczególne charakterystyki mieszkania oddziałują na poziom jego ceny w ogłoszeniu ofertowym. Do estymacji wpływu danych cech zastosowano metody ekonometrii przestrzennej. Zastosowanie GWR i podział na klastry okazało się właściwym podejściem ze względu na heterogeniczność przestrzenną. Przynależność do wszystkich wyodrębnionych klastrów okazała się mieć znaczenie, a więc ceny mieszkań powinny być modelowane przestrzennie. Wyniki wskazują na istnienie zarówno autokorelacji przestrzennej, jak i dryfu przestrzennego. Udało się określić wpływ poszczególnych charakterystyk na cenę mieszkania. Cechy, które okazały się mieć dodatni wpływ na cenę ofertową nieruchomości mieszkaniowych to: winda w budynku, taras, niewielka powierzchnia użytkowa, wysokie piętro oraz bliski dystans do centrum miasta i najbliższej stacji metra. Ujemnym wpływem na cenę mieszkania charakteryzuje się: pośrednictwo nieruchomości, spółdzielcze własnościowe prawo własności, wysoki wiek budynku, balkon, pogorszony stan fizyczny oraz brak wykończenia. Dalsze prace nad tym modelem powinny skupić się na wyodrębnieniu większej ilości zmiennych, a także na wykorzystaniu danych panelowych.



## BIBLIOGRAFIA

- Czerniak, A., Milewska-Wilk, H., Bojć, T., 2021, Zjawisko flippingu na polskim rynku mieszkaniowym, *Studia BAS*, 2(66), s. 195-213.
- Fereidouni, H. G., 2012, The role of real estate agents on housing prices and rents: the Iranian experience, *International Journal of Housing Markets and Analysis*, 5(2), s. 134-144.
- Grupa PKO Banku Polskiego, 2022, Puls Nieruchomości: Szok na rynku najmu. Dostęp 12.2023 r. <https://www.pkobp.pl/centrum-analiz/nieruchomosci/nieruchomosci-mieszkaniowe/puls-nieruchomosci-szok-na-ryнку-najmu/>
- GUS, 2023, Powierzchnia i ludność w przekroju terytorialnym w 2023 roku. Dostęp 12.2023 r. [https://pie.net.pl/wp-content/uploads/2019/06/PIE-Raport\\_Akademickosc-red..pdf](https://pie.net.pl/wp-content/uploads/2019/06/PIE-Raport_Akademickosc-red..pdf)
- Humphreys, B. R., Nowak, A., Zhou, Y., 2019, Superstition and real estate prices: Transaction-level evidence from the US housing market, *Applied Economics*, 51(26), s. 2818-2841.
- Jud, G. D., Frew, J., 1986, Real estate brokers, housing prices, and the demand for housing, *Urban Studies*, 23(1), s. 21-31.
- Kancelaria Prezesa Rady Ministrów, 2023, Szczegółowe statystyki dot. osób zarejestrowanych w rejestrze obywateli Ukrainy i członków ich rodzin, którym nadano status cudzoziemca na podstawie specustawy. Dostęp 12.2023 r. <https://dane.gov.pl/pl/dataset/2715,zarejestrowane-wnioski-o-nadanie-statusu-ukr/resource/46612/table>
- Kokot, S., 2019, Próba oszacowania chłonności rynku mieszkań w Polsce w perspektywie 20 lat, *Mikroekonometria w teorii i praktyce gospodarki nieruchomościami*, Difin, s. 23-44.
- Kokot, S., 2020, Socio-economic factors as a criterion for the classification of housing markets in selected cities in Poland, *Real Estate Management and Valuation*, 28(3), s. 77-90.
- Kucharska-Stasiak, E., 2006, *Nieruchomość w gospodarce rynkowej*, Wydawnictwo Naukowe PWN, s. 17.
- Maloney, M., Rosenthal, S. S., 2022, Why Do Home Prices Appreciate Faster in City Centers? The Role of Risk-Return Trade-Offs in Real Estate Markets, Department of Economics, Syracuse University, s. 1.
- Melichar, J., Kaprová, K., 2013, Revealing preferences of Prague's home buyers towards greenery amenities: The empirical evidence of distance-size effect, *Landscape and Urban Planning*, 109, s. 56-66.
- Müller, S., Wilhelm, P., & Haase, K. (2013). Spatial dependencies and spatial drift in public transport seasonal ticket revenue data. *Journal of Retailing and Consumer Services*, 20(3), 334-348.
- National Geospatial-Intelligence Agency (NGA) Standardization Document, 2014, Department of Defense World Geodetic System 1984: Its Definition and Relationships with Local Geodetic Systems. Dostęp 12.2023 r. <https://nsgreg.nga.mil/doc/view?i=4085>
- NBP, 2022, Informacja o cenach mieszkań i sytuacji na rynku nieruchomości mieszkaniowych i komercyjnych w Polsce w III kwartale 2022 r. Dostęp 12.2023 r. [https://nbp.pl/wp-content/uploads/2022/12/ceny\\_mieszkan\\_09\\_2022.pdf](https://nbp.pl/wp-content/uploads/2022/12/ceny_mieszkan_09_2022.pdf)
- Otręba, A., 2005, Nieruchomości inwestycyjne w ujęciu rachunkowości, *Studia Ekonomiczne/Akademia Ekonomiczna w Katowicach*, 33, s. 191-210.
- Polski Instytut Ekonomiczny, 2019, *Akademickość polskich miast*. Dostęp 12.2023 r.

- Rozporządzenie Ministra Infrastruktury z dnia 12 kwietnia 2002 r. - w sprawie warunków technicznych, jakim powinny odpowiadać budynki i ich usytuowanie (Dz.U. 2022 poz. 1225).
- Tęczak, E., 2023, Dane Otodom Analytics: ceny mieszkań w 5 największych miastach z podziałem na dzielnice. Dostęp 12.2023 r.  
<https://www.otodom.pl/wiadomosci/dane/otodom-analytics/dane-otodom-aktualne-ceny-ofertowe-w-dzielnicach>
- Torzewski, M., 2016, Analiza wpływu lokalizacji stacji metra warszawskiego na ceny mieszkań na przykładzie dzielnicy Ursynów w Warszawie, *Studia i Materiały*, (1/2016 (20)), s. 145-155.
- UNHCR, 2023, Ukraine Situation - 2022 Final Report Regional Refugee Response Plan. Dostęp 12.2023 r. <https://data.unhcr.org/en/documents/download/99791>
- United Nations, 2019, World Urbanization Prospects: The 2018 Revision, Department of Economic and Social Affairs, Population Division, New York: United Nations. Dostęp 12.2023 r. <https://population.un.org/wup/publications/Files/WUP2018-Report.pdf>
- Ustawa z dnia 14 czerwca 2007 r. - o zmianie ustawy o spółdzielniach mieszkaniowych oraz o zmianie niektórych innych ustaw (Dz. U. 2007 nr 125 poz. 873).
- Violand, W., Simon, A., 2007, Real estate brokers: do they inflate housing prices? The case of France, *Bankers, Markets & Investors*, 111, s. 27-41.
- Wen, H., Gui, Z., Zhang, L., Hui, E. C., 2020, An empirical study of the impact of vehicular traffic and floor level on property price, *Habitat international*, 97, 102132, s. 8.
- Wiliński, D., Krański, Ł., Wesołowska, K., Duś, M., Marczak, S., 2017, Wpływ lokalizacji na cenę ofertową nieruchomości na przykładzie ulicy Puławskiej w Warszawie, *Świat Nieruchomości*, 101, s. 69-76.
- Wiśniewska, M. A., 2011, Inwestowanie w nieruchomości na rynkach międzynarodowych: analiza komparatywna efektywności, Wydawnictwo Naukowe PWN, s. 15-23.
- World Bank, 2021, Demographic Trends and Urbanization, Washington, DC. Dostęp 12.2023 r.  
<https://documents1.worldbank.org/curated/en/260581617988607640/pdf/Demographic-Trends-and-Urbanization.pdf>
- Xiao, Y., Hui, E. C., Wen, H., 2019, Effects of floor level and landscape proximity on housing price: A hedonic analysis in Hangzhou, *Habitat International, China*, 87, s. 11-26.